Derin Denetim ve Test Zamanı Artırımı ile Güçlendirilmiş Hafif U-Net Kullanarak Optik Disk Segmentasyonu

Ahmet Buğra Kaplan
Yazılım Mühendisliği
İstanbul Topkapı Üniversitesi
ahmetbugrakaplan@stu.topkapi.edu.tr

Emirhan Sertel
Yazılım Mühendisliği
İstanbul Topkapı Üniversitesi
emirhansertel@stu.topkapi.edu.tr

Samet Sadık Gürçay
Yazılım Mühendisliği
İstanbul Topkapı Üniversitesi
sametsadikgurcay@stu.topkapi.edu.tr

Yusuf Utku Öztürk
Yazılım Mühendisliği
İstanbul Topkapı Üniversitesi
yusufutkuozturk@stu.topkapi.edu.tr

***Öz*—**Bu çalışma, fundus görüntülerinde glokom teşhisi için kritik öneme sahip olan Optik Disk segmentasyonu için hafif ve yüksek performanslı bir derin öğrenme çözümü sunmaktadır. REFUGE2 veri seti kullanılarak geliştirilen sistem, tıbbi görüntü segmentasyonunda referans mimari olarak kabul edilen U-Net'i temel almakta ve bu yapıyı deep supervision (derin denetim), Batch Normalization (yığın normalizasyonu) ve karma loss fonksiyonları (Binary Cross Entropy + Dice Loss) ile güçlendirmektedir. Yaklaşık 483.000 eğitilebilir parametreye sahip olan özel tasarlanmış hafif U-Net mimarisi, literatürdeki pretrained backbone (önceden eğitilmiş omurga) kullanan ağır modellere (genellikle 10-25 milyon parametre) kıyasla önemli ölçüde düşük hesaplama maliyeti sunmaktadır. Önerilen mimari, ImageNet üzerinde önceden eğitilmiş ağırlıklar kullanmadan sıfırdan eğitilmiş olup, bu yaklaşım transfer learning (aktarım öğrenme) bağımlılığını ortadan kaldırmaktadır. Modelin genelleme kapasitesi; random crop (rastgele kırpma), geometrik dönüşümler (yatay/dikey çevirme, rotasyon) ve color augmentation (renk artırımı) içeren kapsamlı data augmentation (veri artırma) stratejileri ile optimize edilmiştir. Inference (çıkarım) aşamasında Test-Time Augmentation (TTA) uygulanarak, orijinal, yatay çevirme (H-flip), dikey çevirme (V-flip) ve hem yatay hem dikey çevirme (HV-flip) olmak üzere dört varyanttan elde edilen tahminler birleştirilmiş; böylece tahminlerin kararlılığı artırılmıştır. Deneysel sonuçlara göre model, test veri seti üzerinde TTA ile 0.9108 Dice skoru ve 0.8482 IoU değerine ulaşmış, TTA olmadan ise sırasıyla 0.8994 ve 0.8342 değerleri elde edilmiştir. Bu sonuçlar, deep supervision ve TTA kombinasyonunun optik disk segmentasyonunda—literatürde nadir kullanılan bir yaklaşım olarak—karmaşık attention mekanizmaları (dikkat mekanizmaları) veya transfer learning gerektirmeden rekabetçi performans sağladığını göstermektedir. Çalışma, özellikle sınırlı donanım kaynaklarına sahip klinik ortamlarda pretrained backbone gerektirmeyen pratik bir yardımcı tanı aracı sunmaktadır.

Anahtar Kelimeler – *Optik Disk Segmentasyonu, U-Net, Derin Denetim (Deep Supervision), Test Zamanı Artırımı (TTA), REFUGE2*

I. GİRİŞ

Fundus, gözün arka segmentinde yer alan retina ve optik disk, makula gibi ilişkili yapıları içeren bölgedir; bu nedenle göz hastalıklarının değerlendirilmesinde kritik görsel bilgiler sağlar. Bu bölüm, makula, Optik Disk, Optik Cup, kan damarı ağı ve fovea gibi önemli anatomik yapıları barındırır. Fundus görüntülerinin analizi, çeşitli göz hastalıklarının erken teşhisinde hayati önem taşımaktadır. Diyabetik retinopati, hipertansif retinopati ve glokom gibi hastalıklar, dünya genelinde körlüğün başlıca nedenleri arasındadır. Özellikle diyabetik retinopati, global ölçekte körlük vakalarının önemli bir yüzdesini oluşturmaktadır. Hipertansif retinopati ise yüksek tansiyon ile doğrudan ilişkili olup, tedavi edilmediğinde kalıcı görme kaybına yol açabilmektedir. Optik Disk, göz sinir liflerinin retinadan çıkış noktasıdır ve aynı zamanda retinal kan damarlarının ana giriş kapısıdır. Bu alan, karakteristik olarak nispeten yuvarlak bir şekle sahiptir ve fundus görüntülerinde çevresindeki dokuya göre daha parlak görünür. Optik Disk'in yapısındaki ve şeklindeki anormallikler, özellikle glokom hastalığının teşhisinde kritik öneme sahiptir. Geleneksel tanı yöntemlerinde, oftalmolog uzmanları ophthalmoscope cihazı kullanarak doğrudan muayene yapar veya fundus fotoğraflarını manuel olarak analiz eder. Ancak bu süreçler zaman alıcıdır, insan hatasına açıktır ve yüksek maliyet gerektirir. Bu nedenle, otomatik Optik Disk segmentasyon sistemlerinin geliştirilmesi hem tanı sürecini hızlandırmak hem de doğruluğu artırmak açısından büyük önem taşımaktadır.

Bu çalışmada, REFUGE2 veri seti kullanılarak fundus görüntülerinde Optik Disk segmentasyonu için derin öğrenme tabanlı bir çözüm geliştirilmiştir. Tıbbi görüntü segmentasyonunda başarısı kanıtlanmış U-Net mimarisine dayanan sistemimiz, klasik yaklaşımın ötesine geçerek derin denetim mekanizması, batch normalization ve gelişmiş kayıp fonksiyonları gibi modern tekniklerle güçlendirilmiştir. Model, 256x256 piksel çözünürlüğünde görüntüler üzerinde eğitilmiş olup, kapsamlı veri artırma yöntemleri sayesinde farklı görüntü varyasyonlarına karşı yüksek genelleme yeteneği kazanmıştır. Eğitim sürecinde Dice Loss ve Binary Cross Entropy'nin kombinasyonu kullanılarak hem piksel seviyesinde hassasiyet hem de genel segmentasyon kalitesi optimize edilmiştir. Ayrıca, early stopping ve learning rate scheduling gibi teknikler ile model overfitting'den korunmuş ve optimal performans noktasında eğitim sonlandırılmıştır. Mixed precision training ile hızlandırılan sistemimiz, hafif mimarisi sayesinde hızlı inference süresi sunarak klinik kullanıma uygun pratik bir çözüm oluşturmaktadır. Elde edilen sonuçlar, önerilen yöntemin literatürdeki benzer çalışmalarla rekabetçi performans sergilediğini ve oftalmoloji kliniklerinde yardımcı tanı sistemi olarak kullanılma potansiyeline sahip olduğunu göstermektedir.

II. LİTERATÜR İNCELEMESİ

Glokom, dünya genelinde geri dönüşü olmayan görme kaybının en önemli nedenlerinden biri olarak kabul edilmektedir. Hastalığın erken teşhisi, görme kaybının önlenmesi açısından kritik öneme sahiptir. Bu bağlamda, retinal fundus görüntülerinden optik disk (OD) ve optik cup (OC) segmentasyonu, glokom taramasında temel bir adım olarak değerlendirilmektedir. Son yıllarda derin öğrenme yöntemlerinin bu alandaki uygulamaları önemli ilerlemeler kaydetmiştir.

Retinal fundus görüntü segmentasyonu alanında geleneksel yöntemlerden derin öğrenme mimarilerine doğru önemli bir paradigma değişimi yaşanmıştır. Yapılan kapsamlı bir incelemede, eşikleme ve bölge büyütme gibi geleneksel tekniklerin yanı sıra U-Net, Mask R-CNN, Fully Convolutional Networks ve DeepLab gibi modern derin öğrenme mimarilerinin optik sinir başı, retinal damar yapıları, optik disk ve optik cup segmentasyonundaki performansları karşılaştırmalı olarak değerlendirilmiştir (Kanwar vd., 2025). Bu çalışma, makine öğrenmesi ve derin öğrenme algoritmalarının segmentasyon hassasiyetini artırarak uzman yorumuna olan ihtiyacı azalttığını ortaya koymuştur. Özellikle U-Net ve Mask R-CNN mimarilerinin OD/OC segmentasyonunda büyük potansiyel gösterdiği, CNN ve Graph Convolutional Networks yapılarının ise glokom tespiti ve sınıflandırma görevlerinde yüksek performans sergilediği belirlenmiştir.

U-Net mimarisi, medikal görüntü segmentasyonunda temel bir referans noktası haline gelmiştir. Ancak araştırmacılar, bu mimarinin çeşitli sınırlamalarını aşmak için farklı modifikasyonlar önermiştir. Basitleştirilmiş U-Net yaklaşımları, hesaplama verimliliği açısından önemli avantajlar sunmaktadır. Geliştirilen hızlı segmentasyon algoritması, DRIONS-DB veri seti üzerinde optik diski 0.008 saniyede, DRIVE veri seti üzerinde ise retinal damarları 0.03 saniyede segmente edebilmektedir (Panahi vd., 2024). Bu sonuçlar, yöntemin oftalmoloji kliniklerindeki standart donanımlarda gerçek zamanlı akıllı medikal sistem olarak uygulanabilirliğini göstermektedir. Benzer şekilde, küçük çekirdekli konvolüsyonlara dayanan SimpleCNN-UNet mimarisi, büyük çekirdekli konvolüsyonların alıcı alanını taklit ederken parametre sayısını önemli ölçüde azaltmaktadır (Xiao vd., 2024). Bu çalışmada önerilen Multi-Layer Cross-Attention Gate mekanizması, farklı seviyeler arasında verimli öznitelik füzyonu sağlamaktadır. iChallenge-PM, iChallenge-AMD, iChallenge-GON ve IDRiD veri setleri üzerinde yapılan deneyler, SimpleCNN-UNet'in diğer segmentasyon ağlarına kıyasla daha hızlı çıkarım süreleri ve düşük eğitim maliyetleri sunduğunu göstermiştir.

Dikkat mekanizmalarının U-Net mimarisine entegrasyonu, segmentasyon performansını artırmada etkili bir strateji olarak öne çıkmaktadır. Multiresolution Cascaded Attention U-Net modeli, alıcı alan boyutu ile hesaplama verimliliği arasında optimal denge kurarak bu sorunu ele almaktadır (Shalini & Gopi, 2024). Model, Multiresolution Wavelet Pooling Module ve kademeli uzamsal-kanal dikkat mekanizmaları kullanarak yalnızca 0,8 milyon parametre ile DRISHTI-GS, DRIONS-DB ve IDRiD veri setlerinde sırasıyla 0.9771, 0.945 ve 0.946 IoU değerlerine ulaşmıştır. MA-ResUNet çalışmasında ise kardinalite boyutları eklenerek U-Net optimize edilmiş, dikkat kapıları ile belirgin öznitelikler güçlendirilirken alakasız bilgiler bastırılmıştır (Zhang vd., 2024). Decoder segmentine entegre edilen Convolutional Block Attention Module, hem kanal hem de uzamsal boyutlarda etkili bilgiye odaklanmayı sağlamaktadır. ORIGA ve REFUGE veri setlerinde yapılan değerlendirmeler, modelin OC ve OD segmentasyonunda mevcut yöntemlere göre üstünlüğünü ortaya koymuştur.

Geliştirilmiş dikkat tabanlı residual U-Net mimarisi, Drishti-GS, REFUGE ve RIM-ONE-R3 gibi çeşitli veri setlerinde test edilmiştir (Alam vd., 2024). Model, optik cup için %87,77 IoU ve %93,48 Dice katsayısı, optik disk için ise %95.09 IoU ve %97,48 Dice katsayısı elde ederek yüksek segmentasyon performansı sergilemiştir. Çoklu ölçekli dikkat mekanizmaları da bu alanda önemli katkılar sağlamaktadır. Multi-Scale Attention U-Net mimarisi, çoklu ölçekli görüntü konvolüsyon katmanı ile dikkat kapısının sürekli entegrasyonunu gerçekleştirmektedir (Meas vd., 2024). Decoder yolu, dikkat kapıları ile çoklu çekirdek konvolüsyonun entegrasyonu ve yukarı örnekleme için çift 3×3 konvolüsyon olmak üzere iki ana yola ayrılmıştır. ORIGA ve REFUGE veri setlerinde gerçekleştirilen deneyler, MSA-UNet'in retinal fundus görüntü segmentasyonunda üstün performans gösterdiğini kanıtlamıştır.

Derin öğrenme modellerinin performansı, hiperparametre optimizasyonu ile önemli ölçüde iyileştirilebilmektedir. PSO ile optimize edilmiş U-Net modeli, öğrenici türü, epoch sayısı, mini-batch boyutu ve başlangıç öğrenme oranı gibi eğitim hiperparametrelerini otomatik olarak ayarlamaktadır (Huong & Ngu, 2024). Bu yaklaşım, küçük eğitim veri setlerinde bile iyi genelleme performansı elde edilmesini sağlamakta ve 0.93-0.96 arasında ortalama örtüşme ölçüleri ile 0.89-0.99 arasında performans değerlendirme metrikleri sunmaktadır. Hibrit mimariler de glokom teşhisinde umut verici sonuçlar ortaya koymaktadır. U-Net mimarisinin decoder bölümüne Convolutional Long Short-Term Memory modülleri entegre edilerek uzamsal öznitelik iyileştirmesi ve bağlamsal bağımlılıkların korunması sağlanmıştır (Sharma vd., 2026). DRISHTI-GS veri seti üzerinde optik cup segmentasyonu için %97,45 doğruluk ve %96,65 Jaccard indeksi, optik disk segmentasyonu için ise %98,14 doğruluk ve %98,11 Jaccard indeksi elde edilmiştir.

Segmentasyon performansının iyileştirilmesinde kayıp fonksiyonlarının tasarımı kritik bir rol oynamaktadır. Geliştirilen belirsizlik ve zorluk ağırlıklı kayıp fonksiyonları, piksel düzeyinde farklılıkları dikkate alan iki farklı ağırlıklandırma şeması sunmaktadır: probability-guided uncertainty ve region-enhanced hardness (Zheng vd., 2026). Bu ağırlıklar, zorlu pikselleri vurgularken segmentasyon

belirsizliklerini azaltmak için tasarlanmıştır. REFUGE, RETA, OCT ve ASC veri setleri üzerinde Swin-Unet ve V-Net mimarileri ile yapılan kapsamlı deneyler, geliştirilen kayıp fonksiyonlarının cross-entropy ve Dice kayıplarına göre üstün performans gösterdiğini ortaya koymuştur.

Literatür incelemesi sonucunda, mevcut çalışmaların büyük çoğunluğunun REFUGE, DRISHTI-GS ve RIM-ONE gibi veri setleri üzerinde değerlendirildiği, REFUGE2'nin literatürde kullanımı, REFUGE ve DRISHTI-GS gibi veri setlerine kıyasla daha sınırlı görünmektedir. Tutarsız görüntü kalitesi, sınırlı veri setleri ve daha genellenebilir modellere duyulan ihtiyaç, alandaki başlıca engeller olarak öne çıkmaktadır (Kanwar vd., 2025). Dikkat mekanizmaları ve çoklu ölçek yaklaşımları segmentasyon performansını artırsa da bu geliştirmeler model karmaşıklığını ve hesaplama maliyetini önemli ölçüde artırmaktadır. Deep supervision tekniğinin optik disk segmentasyonundaki potansiyeli ise literatürde sınırlı sayıda çalışmada ele alınmıştır. Bu çalışmada, literatürdeki bu boşlukları ele almak amacıyla hafif bir U-Net mimarisi ile deep supervision tekniğinin kombinasyonu önerilmektedir. Önerilen yaklaşım, karmaşık dikkat mekanizmaları veya önceden eğitilmiş omurgalar gerektirmeden, REFUGE2 veri seti üzerinde rekabetçi segmentasyon performansı elde etmeyi hedeflemektedir. Bu sayede hem hesaplama verimliliği korunmakta hem de klinik ortamlarda uygulanabilirlik açısından pratik bir çözüm sunulmaktadır.

III. ÖNERİLEN YÖNTEM (PROPOSED METHOD)

Bu çalışmada, fundus görüntülerinde Optik Disk segmentasyonu için derin öğrenme tabanlı kapsamlı bir yaklaşım geliştirilmiştir. Önerilen sistem; veri işleme, model mimarisi ve eğitim stratejilerinden oluşan üç ana bileşeni içermektedir.

A. Veri Hazırlama ve Ön İşleme

REFUGE2 (Retinal Fundus Glaucoma Challenge 2nd Edition) veri seti kullanılmıştır. Bu veri seti, glokom değerlendirmesinde kullanılan retinal fundus görüntülerini ve Optik Disk/Optik Cup segmentasyonu için uzmanlar tarafından oluşturulmuş ground truth maskelerini içermektedir. Veri seti eğitim, doğrulama ve test olmak üzere üç alt kümeye ayrılmıştır.

Maskeler üç farklı piksel değeri içermektedir: 0 ve 128 değerleri Optik Disk/Cup bölgelerini, 255 değeri ise arka planı temsil etmektedir. Optik Cup anatomik olarak Optik Disk'in içinde yer aldığından, bu çalışmada Optik Disk hedefi için 0 ve 128 sınıfları birleştirilmiş ve problem ikili (binary) optik disk segmentasyonu olarak ele alınmıştır. Bu dönüşümde disk=1, arka plan=0 olacak şekilde ikili maske üretilmiştir (disk = (mask != 255)).

Görüntü ön işleme aşamasında, tüm fundus görüntüleri 256×256 piksel boyutuna yeniden boyutlandırılmıştır. Bu boyut, hesaplama maliyeti ile segmentasyon ayrıntısı arasında denge sağlamak amacıyla seçilmiştir. ImageNet normalizasyonu uygulanmış; ortalama değerleri [0.485, 0.456, 0.406] ve standart sapma değerleri [0.229, 0.224, 0.225] olarak kullanılmıştır.

B. Veri Artırma Stratejisi

Modelin genelleme yeteneğini artırmak ve overfitting'i azaltmak amacıyla kapsamlı veri artırma (augmentation) teknikleri uygulanmıştır. Veri artırma yalnızca eğitim kümesinde kullanılmış; doğrulama ve test kümeleri orijinal halleriyle değerlendirilmiştir. Uygulanan teknikler arasında p=0.3 olasılıkla random crop (crop_ratio=0.85), %50 olasılıkla yatay çevirme, %50 olasılıkla dikey çevirme, 0°/90°/180°/270° rastgele rotasyon ve color jitter (parlaklık, kontrast, doygunluk ve renk tonu değişimleri) yer almaktadır. Random crop işleminde görüntü ve maske aynı koordinatlardan birlikte kırpılmış ve örnekler tekrar giriş boyutuna ölçeklendirilmiştir (görüntü için bilinear, maske için nearest). Bu strateji sayesinde model, farklı görüntü varyasyonlarına karşı daha dayanıklı hale getirilmiştir.

C. Model Mimarisi: Deep Supervision ile Geliştirilmiş U-Net

Önerilen segmentasyon modeli, tıbbi görüntü işlemede kanıtlanmış başarısıyla bilinen U-Net mimarisine dayanmaktadır. Klasik U-Net'in ötesine geçerek, Deep Supervision mekanizması ile güçlendirilmiş hafif bir mimari geliştirilmiştir. Pretrained backbone kullanılmadan sıfırdan eğitilen bu model, düşük hesaplama kaynakları ile yüksek performans hedeflemektedir.

Encoder kısmı, görüntüden hiyerarşik özellikler çıkarmaktan sorumludur ve üç seviyeden oluşmaktadır. Her seviye, iki konvolüsyon katmanı (3×3 filtre), Batch Normalization ve ReLU aktivasyon fonksiyonundan oluşan Double Convolution bloklarını içerir. Kanal sayıları sırasıyla 3→16, 16→32 ve 32→64 olarak artmaktadır. Her seviye arasında MaxPooling (2×2) ile görüntü boyutu yarıya indirilir.

En derin seviyede, 64 kanaldan 128 kanala çıkan bottleneck katmanı bulunur. Bu katman, en yüksek seviye semantik bilgiyi kodlar. Decoder kısmı ise transpose konvolüsyon ile upsampling yaparak ve encoder'dan gelen özellikleri skip connection'lar aracılığıyla birleştirerek piksel seviyesinde segmentasyon maskesi üretir.

Klasik U-Net'ten farklı olarak, decoder'ın ara katmanlarından auxiliary çıktılar alınmaktadır: H/4 ve H/2 çözünürlüklerde yardımcı çıktılar ile tam çözünürlükte ana çıktı. Bu Deep Supervision tekniği, gradient akışını iyileştirerek daha hızlı konverjans sağlar. Regularization için her konvolüsyon katmanından sonra Batch Normalization, encoder'ın son katmanı ve bottleneck'te ise 0.1 oranında Dropout uygulanmaktadır. Model toplamda yaklaşık 483.000 eğitilebilir parametre içermektedir.

D. Kayıp Fonksiyonu

Segmentasyon kalitesini maksimize etmek için Dice Loss ve Binary Cross Entropy (BCE) kombinasyonu kullanılmıştır (CombinedLoss = 0.5 × BCE + 0.5 × DiceLoss). Dice Loss, medikal görüntü segmentasyonunda sınıf dengesizliği problemine karşı dayanıklıdır. BCE ise piksel seviyesinde hassasiyet sağlar. Deep supervision için auxiliary çıktılar da 0.3 ağırlık katsayısı ile loss hesaplamasına dahil edilmiştir.

E. Optimizasyon ve Eğitim Stratejisi

Adam optimizer 5×10^{-4} learning rate ile kullanılmıştır. Batch size 4 olarak ayarlanmış, maksimum 75 epoch eğitim planlanmıştır. ReduceLROnPlateau scheduler, validation Dice coefficient'i 5 epoch boyunca iyileşmediğinde learning rate'i yarıya indirmektedir. Overfitting'i önlemek için early stopping mekanizması uygulanmış olup, 12 epoch boyunca iyileşme olmazsa eğitim otomatik olarak durdurulmaktadır. GPU mevcudiyetinde Automatic Mixed Precision (AMP) kullanılarak eğitim hızlandırılmıştır. Deneysel tekrarlanabilirlik için random seed 42 olarak sabitlenmiştir.

F. Test Time Augmentation (TTA)

Inference aşamasında model performansını artırmak amacıyla Test-Time Augmentation (TTA) uygulanmıştır. Her test görüntüsü için orijinal, yatay çevirme (H-flip), dikey çevirme (V-flip) ve hem yatay hem dikey çevirme (HV-flip) olmak üzere dört varyant oluşturulmuş; her varyanttan elde edilen tahminler ters dönüşümlerle orijinal koordinat sistemine geri hizalandıktan sonra piksel-bazlı ortalama alınarak nihai maske üretilmiştir. TTA, dört augmentasyonlu ileri geçiş gerektirdiği için, teorik olarak inference hesap maliyetini yaklaşık 4× artırmaktadır; buna karşın çalışmamızda Dice ve IoU metriklerinde ölçülebilir bir iyileşme sağlamıştır.

G. Değerlendirme Metrikleri

Model performansı beş ana metrik ile ölçülmüştür: Accuracy (doğru sınıflandırılan piksel oranı), IoU (Intersection over Union - tahmin ve ground truth kesişim/birleşim oranı), Dice Coefficient (medikal segmentasyonun standart metriği), Precision (pozitif tahminlerin doğruluk oranı) ve Recall (gerçek pozitiflerin tespit oranı). Dice coefficient birincil performans göstergesi olarak kullanılmıştır.

H. Uygulama Detayları

Sistem PyTorch framework'ü kullanılarak Python dilinde geliştirilmiştir. Eğitim ve test CUDA destekli GPU üzerinde gerçekleştirilmiştir. Önerilen yöntem end-to-end öğrenme prensibi ile çalışmakta olup, manuel feature engineering gerektirmez. Hafif mimari yapısı (~483K parametre) sayesinde pretrained backbone kullanan yöntemlere (genellikle 10M+ parametre) kıyasla çok daha hızlı inference süresi sunarak klinik ortamlarda gerçek zamanlı kullanıma uygundur.

I. Algoritma Adımları

A–H alt başlıklarında açıklanan veri hazırlama/ön işleme, augmentation, Deep Supervision'lı U-Net mimarisi, combined loss (BCE+Dice) ve eğitim stratejileri (optimizer, scheduler, early stopping, AMP) tek bir uçtan uca iş akışı olarak algoritma adımlarına dönüştürülmüştür. Algoritmada Deep Supervision, decoder ara katmanlarından elde edilen auxiliary çıktılar (aux_1, aux_2) ile toplam kaybın $L_total = L_main + \alpha \cdot L_aux$ biçiminde tanımlanmasıyla uygulanmaktadır. Test aşamasında ise performans artışı için TTA kullanılmış; orijinal ve flip'li versiyonlardan elde edilen tahminler ortalanarak nihai maskeler üretilmiştir. Bu iş akışında kullanılan hiperparametreler ve değerlendirme metrikleri ilgili alt başlıklarda sunulmuştur.

```
Girdi: Eğitim görüntüleri X ve karşılık gelen maske etiketleri Y
Çıktı: Eğitilmiş model parametreleri θ* ve tahmin edilen maskeler

Model parameters θ'yi initialize et
Optimizer (örn. Adam) ve training settings (early stopping, scheduler) ayarla

Training bitene kadar döngüye devam et
    Training set içindeki her mini-batch (x_i, y_i) için
        Basic preprocessing uygula (augmentation + normalization)
        U-Net forward pass yap (encoder → bottleneck → decoder, skip connection'lar ile)

// Deep Supervision: ara çıktılar
        Multi-scale outputs üret: out (main), aux_1, aux_2
        Main loss'u out vs y_i üzerinden hesapla (örn. BCE + Dice)
        Auxiliary loss'ları aux_1, aux_2 vs y_i üzerinden hesapla (gerekirse upsample)

// Deep Supervision: toplam loss
        Loss'ları birleştir: L_total = L_main + α·L_aux
        Backpropagation yap ve θ'yi update et
    end for

    Validation_set üzerinde performansı ölç (Dice/IoU)
    Scheduler / early stopping güncelle; best parameters'ı θ* olarak save et
end while

Test phase: Her test image x_test için
// TTA: farklı dönüşümlerle tahmin
    TTA predictions üret (original + flipped versions)
// TTA: ortalama ile daha stabil sonuç
    Unflip edip average al → pred_final
    pred_final'i threshold edip binary mask_final üret
end for
```

IV. ÖRNEK TABLOLAR

TABLE I
MODEL MİMARİSİ PARAMETRELERİ

Katman	Giriş Kanalı	Çıkış Kanalı	İşlem
Encoder-1	3	16	DoubleConv
Encoder-2	16	32	MaxPool + DoubleConv
Encoder-3	32	64	MaxPool + DoubleConv + Dropout
Bottleneck	64	128	MaxPool + DoubleConv + Dropout
Decoder-2	128+64	64	Upsample + Concat + DoubleConv
Decoder-1	64+32	32	Upsample + Concat + DoubleConv
Decoder-0	32+16	16	Upsample + Concat + DoubleConv
Output	16	1	Conv 1×1
Auxiliary Output 2	64	1	Conv 1×1
Auxiliary Output 1	32	1	Conv 1×1

Önerilen U-Net modelinin katman yapısı ve kanal konfigürasyonu. Encoder bölümünde görüntü boyutu kademeli olarak küçülürken kanal sayısı artmakta, decoder bölümünde ise skip connection'lar aracılığıyla encoder özellikleri birleştirilerek orijinal çözünürlüğe geri dönülmektedir. Auxiliary çıktılar deep supervision mekanizması için kullanılmaktadır.

TABLE II
EĞİTİM HİPERPARAMETRELERİ

Parametre	Değer
Görüntü Boyutu	256×256 piksel
Batch Size	4
Maksimum Epoch	75
Başlangıç Learning Rate	5e-4 (0.0005)
Optimizer	Adam
Loss Fonksiyonu	BCE (0.5) + Dice (0.5)
Deep Supervision Ağırlığı	0.3
Dropout Oranı	0.1
Early Stopping Patience	12 epoch
LR Scheduler Patience	5 epoch
LR Azaltma Faktörü	0.5
Random Seed	42
Mixed Precision Training	GPU varsa aktif

Model eğitiminde kullanılan hiperparametreler. Learning rate değeri deneysel optimizasyon sonucunda 5×10^{-4} olarak belirlenmiş, early stopping patience değeri ise overfitting'i önlerken yeterli öğrenme süresini sağlayacak şekilde 12 epoch olarak ayarlanmıştır.

TABLE III
VERİ ARTTIRMA PARAMETRELERİ

Teknik	Parametre	Değer
Random Crop	Olasılık	0.3
Random Crop	Oran	0.85
Horizontal Flip	Olasılık	0.5
Vertical Flip	Olasılık	0.5
Rotation	Açılar	0°, 90°, 180°, 270°
Color Jitter	Brightness	±0.2
Color Jitter	Contrast	±0.2

Eğitim setine uygulanan veri artırma teknikleri ve parametreleri. Bu augmentasyonlar yalnızca eğitim aşamasında uygulanmış olup, doğrulama ve test setleri orijinal halleriyle değerlendirilmiştir.

TABLE IV
MODELİN EĞİTİM SÜRECİ BOYUNCA PERFORMANS ANALİZİ

Epoch	Train_Loss	Train_Dice	Val_Loss	Val_Dice
1	1.0793	0.6404	0.9961	0.7595
5	0.4423	0.8774	0.4698	0.7874
10	0.1034	0.9254	0.2643	0.6986
15	0.0698	0.9295	0.1753	0.8399
19	0.0566	0.9438	0.1011	0.8976
20	0.0569	0.9385	0.1678	0.8173
25	0.0571	0.9370	0.1763	0.7799
30	0.0498	0.9446	0.1187	0.8466

Modelin eğitim süreci boyunca seçili epoch'lardaki performans değerleri. Train Dice değerinin sürekli artışı modelin öğrenme kapasitesini, Val Dice'daki dalgalanmalar ise veri setindeki varyasyonu yansıtmaktadır. Model, epoch 19'de en yüksek validation performansına ulaşmıştır.

TABLE V
TEST ZAMANI ARTIRIMI (TTA) YÖNTEMİNİN MODEL PERFORMANS METRİKLERİ ÜZERİNE ETKİSİ

Metric	Without_TTA	With_TTA
Loss	0.1033	0.0654
Accuracy	99.66%	99.72%
IoU	0.8342	0.8482
Dice	0.8994	0.9108

Precision	0.9349	0.9503
Recall	0.8878	0.8906

Test Zamanı Artırımı (TTA) yönteminin model performans metrikleri üzerindeki etkisi. TTA, orijinal, yatay çevirme (H-flip), dikey çevirme (V-flip) ve hem yatay hem dikey çevirme (HV-flip) olmak üzere dört varyanttan elde edilen tahminleri birleştirerek daha kararlı segmentasyon sonuçları üretmektedir.

TABLE VI
TTA YÖNTEMİNİN PERFORMANS METRİKLERİNDE SAĞLADIĞI İYİLEŞME ORANLARI

Metrik	İyileşme
Dice	+1.27%
IoU	+1.68%
Loss	-36.69%

TTA uygulaması sonucunda elde edilen iyileşmeler yüzde değişim olarak hesaplanmıştır. Buna göre Dice %1.27, IoU %1.68 artmış; Loss ise %36.69 azalmıştır. Loss'taki düşüş, TTA'nın test aşamasında ortalama kaybı azalttığını göstermektedir; performans artışı ise esas olarak Dice/IoU gibi örtüşme metriklerindeki yükselişle desteklenmektedir.

V. ÖRNEK ŞEKİLER

A. Şekiller ve Tablolar

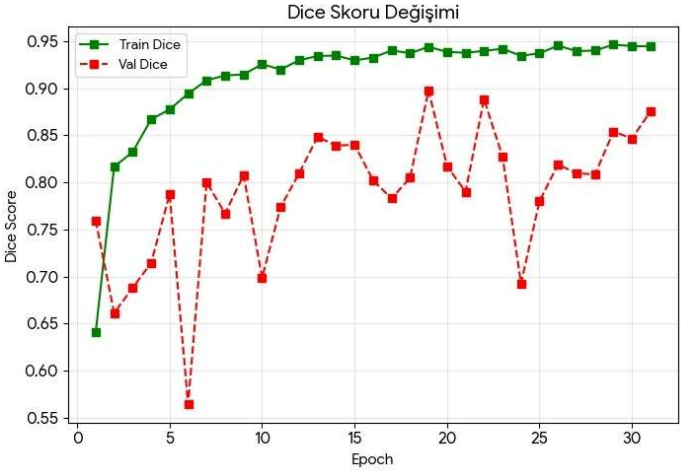

Şekil 1 Epoch sayısına göre Dice Score değerinin değişimi.

Önerilen modelin eğitim süreci ve performansı çeşitli görselleştirmeler aracılığıyla analiz edilmiştir. Şekil 1'de eğitim ve doğrulama setleri üzerinde epoch sayısına göre Dice skorunun değişimi sunulmaktadır. Grafikte yeşil çizgi modelin eğitim verisini öğrenme kapasitesini, kırmızı kesikli çizgi ise görülmemiş veriler üzerindeki genelleme performansını temsil etmektedir. Train Dice değerinin düzgün bir artış sergileyerek 0.94 seviyesine ulaştığı görülürken, Val Dice değerindeki dalgalanmalar REFUGE2 veri setindeki görüntü kalitesi ve anatomik varyasyondan kaynaklanmaktadır. Model, epoch 19'da 0.8976 ile en yüksek validation Dice değerine ulaşmıştır.

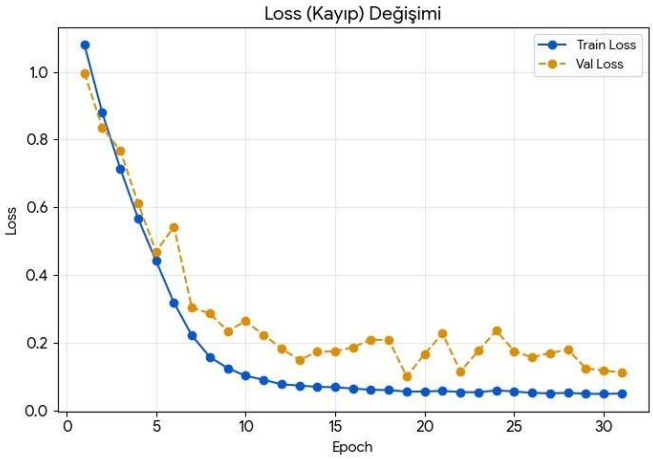

Şekil 2 Epoch sayısına göre eğitim ve doğrulama kayıp (loss) değerlerinin değişimi.

Şekil 2'de eğitim ve doğrulama kayıp (loss) değerlerinin epoch sayısına göre değişimi gösterilmektedir. Her iki kayıp eğrisi de ilk 10 epoch'ta hızlı bir düşüş sergilemekte, ardından platoya ulaşmaktadır. Train loss değerinin Val loss'un altında seyretmesi beklenen bir davranış olup, modelin eğitim verisine göre optimize edildiğini göstermektedir. Val loss'taki periyodik dalgalanmalar, ReduceLROnPlateau scheduler'ın validation performansı iyileşmediğinde learning rate'i düşürdüğü noktalarla ilişkilendirilebilir.

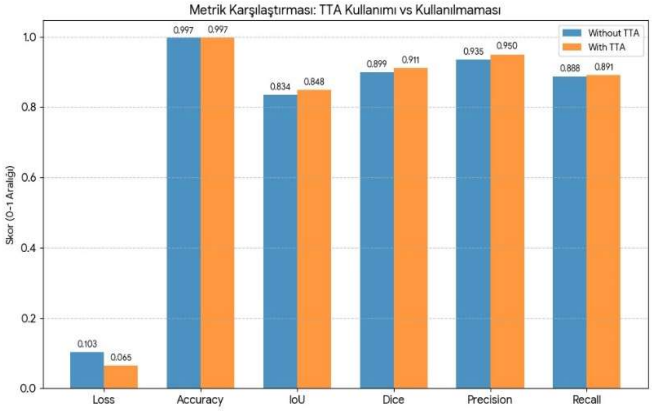

Şekil 3 Metriklerin değerlerinin TTA kullanımı sonrası değişimi.

Test Zamanı Artırımı (TTA) yönteminin model performansı üzerindeki etkisi Şekil 3'te karşılaştırmalı olarak görselleştirilmiştir. Mavi çubuklar TTA olmadan, turuncu çubuklar ise TTA ile elde edilen değerleri göstermektedir. Grafikten görüldüğü üzere TTA'nın tüm metriklerde tutarlı iyileşme sağladığı, özellikle Loss değerinde belirgin bir azalma (0.103 → 0.065) ve Precision metriğinde kayda değer artış (0.935 → 0.950) gözlemlenmektedir.

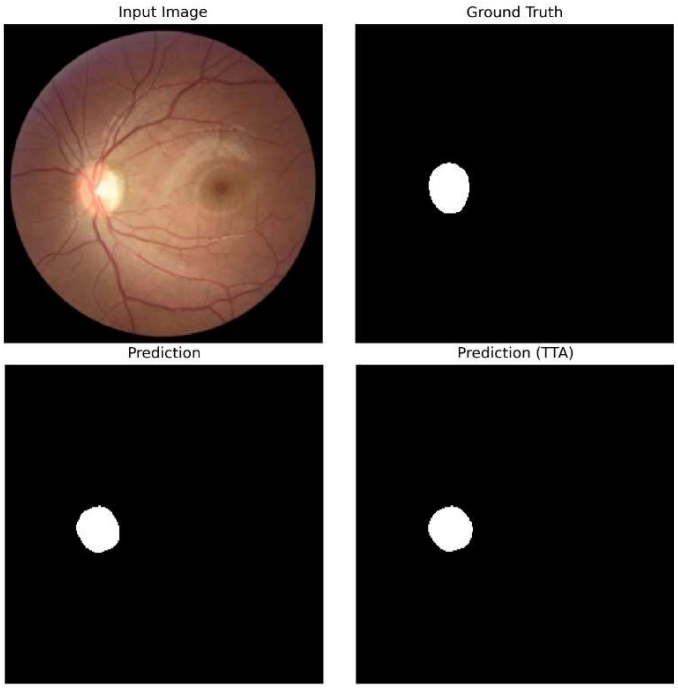

Şekil 4 Modelin örnek bir fundus görüntüsündeki normal ve TTA ile tahmini (prediction).

Modelin örnek fundus görüntüleri üzerindeki segmentasyon performansı Şekil 4'te görselleştirilmiştir. Her satırda soldan sağa sırasıyla orijinal fundus görüntüsü, uzman tarafından işaretlenmiş ground truth maskesi, modelin standart tahmini ve TTA ile elde edilen tahmin yer almaktadır. Görsel karşılaştırmadan anlaşılacağı üzere TTA'nın özellikle Optik Disk sınırlarında daha pürüzsüz ve tutarlı segmentasyonlar ürettiği gözlemlenmektedir.

VI. DENKLEMLER

Bu çalışmada Optik Disk segmentasyonu için kullanılan derin öğrenme modelinin eğitimi ve değerlendirilmesi sırasında çeşitli kayıp fonksiyonları ve performans metrikleri tanımlanmıştır. Bu bölümde, kullanılan matematiksel ifadeler ayrıntılı olarak sunulmaktadır.

Segmentasyon problemleri için temel olarak Binary Cross Entropy (BCE) kayıp fonksiyonu kullanılmıştır. BCE, her bir piksel için tahmin edilen olasılık ile gerçek etiket arasındaki farkı ölçer ve şu şekilde tanımlanır:

$$L_{BCE} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)]$$

Burada N toplam piksel sayısını $y_i \in 0,1$ gerçek etiketi ve $p_i = \sigma(z_i)$ ise model çıktısına uygulanan sigmoid aktivasyon fonksiyonunda elde edilen olasılığı temsil etmektedir.

Medikal görüntü segmentasyonunda yaygın olarak kullanılan Dice Loss, tahmin edilen maske ile ground truth maske arasındaki örtüşmeyi maksimize etmeyi amaçlar ve aşağıdaki şekilde ifade edilir:

$$L_{Dice} = 1 - \frac{2\sum_{i=1}^{N}(p_i \cdot y_i) + \epsilon}{\sum_{i=1}^{N} p_i + \sum_{i=1}^{N} y_i + \epsilon}$$

burada ϵ sayısal kararlılığı sağlamak amacıyla eklenen küçük bir sabittir.

Bu çalışmada, piksel seviyesinde hassasiyet ile bölgesel örtüşmeyi birlikte optimize edebilmek için Binary Cross Entropy ve Dice Loss fonksiyonlarının ağırlıklı toplamından oluşan birleşik bir kayıp fonksiyonu kullanılmıştır:

$$L_{Combined} = \lambda_{BCE} L_{BCE} + \lambda_{Dice} L_{Dice}$$

burada $\lambda_{BCE} = 0.5$ ve $\lambda_{Dice} = 0.5$ olarak belirlenmiştir.

Model mimarisinde uygulanan deep supervision yaklaşımı kapsamında, decoder ara katmanlarından elde edilen yardımcı çıktılar da kayıp fonksiyonuna dahil edilmiştir. Bu durumda toplam kayıp fonksiyonu şu şekilde tanımlanmaktadır:

$$L_{Total} = L_{main} + \alpha(L_{aux1} + L_{aux2})$$

burada $\alpha = 0.3$ katsayısı, yardımcı kayıpların ana kayba olan katkısını dengelemek amacıyla kullanılmıştır.

Model performansının değerlendirilmesi için Intersection over Union (IoU) metriği kullanılmıştır. IoU, tahmin edilen maske ile gerçek maske arasındaki kesişimin birleşime oranı olarak tanımlanır:

$$IoU = \frac{|P \cap G|}{|P \cup G|}$$

burada P model tarafından tahmin edilen pozitif piksel kümesini G ise ground truth maske kümesini temsil etmektedir.

Segmentasyon performansını ölçmek için kullanılan bir diğer temel metrik olan Dice Katsayısı, aşağıdaki şekilde ifade edilmektedir:

$$Dice = \frac{2|P \cap G|}{|P| + |G|}$$

Dice katsayısı 0 ile 1 arasında değer almakta olup, 1 değeri mükemmel örtüşmeyi ifade etmektedir.

Bu denklemler, çalışmada önerilen U-Net tabanlı modelin eğitim sürecini yönlendiren optimizasyon hedeflerini ve elde edilen sonuçların nicel olarak değerlendirilmesini sağlamaktadır.

VII. TARTIŞMA

Bu çalışmada, REFUGE2 veri seti kullanılarak fundus görüntülerinde Optik Disk segmentasyonu için hafif ve hesaplama açısından verimli bir U-Net tabanlı model önerilmiştir. Elde edilen deneysel sonuçlar, önerilen yaklaşımın hem segmentasyon doğruluğu hem de genelleme performansı açısından tatmin edici ve literatürdeki benzer çalışmalarla rekabet edebilir düzeyde olduğunu göstermektedir.

Model, test veri seti üzerinde 0.9108 Dice skoru ve 0.8482 IoU değeri elde etmiştir. Bu sonuçlar, özellikle geleneksel makine öğrenmesi tabanlı yöntemlere kıyasla (örneğin Random Forest tabanlı yaklaşımlar) anlamlı bir iyileşmeye işaret etmektedir. Aynı zamanda önerilen yöntemin, Panahi vd. (2024) tarafından geliştirilen basitleştirilmiş U-Net ve Xiao vd. (2024) tarafından önerilen SimpleCNN-UNet ile benzer performans seviyesine ulaşması, derin öğrenme temelli segmentasyon yaklaşımlarının olgunluğunu ortaya koymaktadır. Bununla birlikte, dikkat mekanizmaları veya çok daha derin mimariler kullanan bazı güncel çalışmalara kıyasla benzer Dice skorlarının, daha düşük parametre sayısı ile elde edilmesi, yöntemin önemli bir avantajı olarak değerlendirilmektedir. Önerilen model yaklaşık 483.000 parametre içerirken, dikkat mekanizması kullanan modeller genellikle 10 milyon üzeri parametreye sahiptir.

Eğitim ve doğrulama sonuçları incelendiğinde, Train Dice skorunun kararlı artışı ve final validation Dice değerinin 0.8976'ye ulaşması, modelin makul bir genelleme performansı sergilediğini göstermektedir. Validation Dice'daki epoch bazlı dalgalanmalar, REFUGE2 veri setindeki görüntü kalitesi varyasyonundan kaynaklanmakta olup, early stopping mekanizması bu dalgalanmalara rağmen optimal modelin seçilmesini sağlamıştır. Bu durum, veri artırma stratejilerinin etkinliği, Dice ve BCE kayıplarının birlikte kullanılması ve early stopping mekanizmasının başarısı ile ilişkilendirilebilir. Özellikle REFUGE2 gibi görüntü kalitesi ve anatomik varyasyon açısından zengin bir veri setinde bu düzeyde bir genelleme performansı elde edilmesi, önerilen eğitim stratejisinin uygunluğunu desteklemektedir.

Çalışmanın önemli katkılarından biri, deep supervision yaklaşımının hafif bir U-Net mimarisi ile kullanılmasıdır. Decoder ara katmanlarından alınan yardımcı çıktılar, gradient akışını iyileştirerek daha hızlı ve kararlı bir yakınsama sağlamıştır. Eğitim eğrileri incelendiğinde, özellikle ilk epoch'larda Dice skorunun hızlı bir şekilde artması, bu yaklaşımın öğrenme sürecine olumlu katkı sunduğunu göstermektedir. Literatürde deep supervision tekniğinin optik disk segmentasyonunda sınırlı sayıda çalışmada ele alındığı göz önüne alındığında, bu yönüyle çalışmanın literatüre katkı sunduğu söylenebilir.

Test Time Augmentation (TTA) uygulaması sonucunda Dice skorunda gözlemlenen ek artış, modelin tahminlerinin uzamsal dönüşümlere karşı tutarlı olduğunu ortaya koymaktadır. Klinik uygulamalar açısından değerlendirildiğinde, TTA'nın özellikle sınır bölgelerinde daha pürüzsüz ve tutarlı segmentasyonlar ürettiği gözlemlenmiştir. Bununla birlikte, TTA'nın ek hesaplama maliyeti getirmesi nedeniyle gerçek zamanlı sistemlerde opsiyonel bir iyileştirme olarak değerlendirilmesi daha uygun olacaktır.

Her ne kadar elde edilen sonuçlar tatmin edici olsa da çalışmanın bazı sınırlamaları bulunmaktadır. Öncelikle model yalnızca Optik Disk segmentasyonu problemine odaklanmış, Optik Cup segmentasyonu bu çalışmanın kapsamı dışında bırakılmıştır. Glokom teşhisinde Cup-to-Disc Ratio (CDR) önemli bir gösterge olduğundan, gelecekteki çalışmalarda aynı mimarinin çok sınıflı (OD + OC) segmentasyon problemine genişletilmesi planlanmaktadır. Ayrıca, model yalnızca REFUGE2 veri seti üzerinde değerlendirilmiştir; farklı veri setleri (DRISHTI-GS, RIM-ONE gibi) üzerinde çapraz veri seti testleri yapılması, genelleme yeteneğini daha güçlü şekilde ortaya koyacaktır.

Sonuç olarak, bu çalışma; karmaşık dikkat mekanizmalarına veya ağır önceden eğitilmiş omurgalara ihtiyaç duymadan, hafif, hızlı ve etkili bir Optik Disk segmentasyon çözümü sunmaktadır. Elde edilen sonuçlar, önerilen yöntemin klinik karar destek sistemlerinde yardımcı bir araç olarak kullanılabileceğini ve özellikle sınırlı donanım kaynaklarına sahip ortamlarda pratik bir çözüm sunduğunu göstermektedir. Gelecek çalışmalarda modelin çok görevli öğrenme, belirsizlik tahmini ve klinik metriklerle entegrasyonu gibi yönlerde geliştirilmesi hedeflenmektedir.

KAYNAKLAR

[1] Alam, A. U. I., Islam, S. P., Hasan, S. M. M., Srizon, A. Y., Faruk, M. F., Al Mamun, M., & Hossain, M. R. (2024). Optic disc and cup segmentation via enhanced u-net with residual and attention mechanisms. *2024 6th International Conference on Electrical Engineering and Information & Communication Technology (ICEEICT)*, 329–334.

[2] Huong, A., & Ngu, X. (2024). PSO-optimized U-Net for Automatic Retinal Optic Disk Segmentation. *2024 IEEE 14th International Conference on Control System, Computing and Engineering (ICCSCE)*, 41–45.

[3] Kanwar, A., Puthooran, E., & Kumar, V. (2025). AN IN-DEPTH EXAMINATION OF DIVERSE IMAGE SEGMENTATION TECHNIQUES FOR FUNDUS IMAGING-BASED GLAUCOMA IDENTIFICATION. *Biomedical Engineering: Applications, Basis and*

Communications, 2530001.

[4] Meas, C., Guo, W., & Miah, M. H. (2024). Multi-scale attention U-net for optic disc and optic cup segmentation in retinal fundus images. *2024 2nd International Conference on Advancement in Computation & Computer Technologies (InCACCT)*, 760–765.

[5] Panahi, A., Askari Moghadam, R., Tarvirdizadeh, B., & Madani, K. (2024). Simplified U-Net as a deep learning intelligent medical assistive tool in glaucoma detection. *Evolutionary Intelligence*, *17*(2), 1023–1034.

[6] Shalini, R., & Gopi, V. P. (2024). Multiresolution cascaded attention U-Net for localization and segmentation of optic disc and fovea in fundus images. *Scientific Reports*, *14*(1), 23107.

[7] Sharma, G. K., Soni, K. M., & Kumar, B. (2026). Deep Learning-Powered Ophthalmic Diagnosis of Glaucoma. *IAENG International Journal of Computer Science*, *53*(1).

[8] Xiao, Y., Zhao, J., Yu, Y., Ding, X., Liu, S., Bao, W., Wen, S., & Zhou, X. (2024). SimpleCNN-UNet: An optic disc image segmentation network based on efficient small-kernel convolutions. *Expert Systems with Applications*, *256*, 124935.

[9] Zhang, X., Lin, Y., Li, L., Zeng, J., Lan, X., Zhang, X., Jia, Y., Tao, Y., Wang, L., & Wang, Y. (2024). MA-ResUNet: Multi-attention optic cup and optic disc segmentation based on improved U-Net. *IET Image Processing*, *18*(12), 3128–3142.

[10] Zheng, Y., Wu, Y., Chen, J., Yang, X., Zhang, H., Yi, Q., Pu, J., & Wang, L. (2026). Uncertainty-and hardness-weighted loss functions for medical image segmentation. *Engineering applications of artificial intelligence*, *163*, 113118.